






Fetal Health Classification

Classify the health of a fetus as Normal, Suspect or Pathological using CTG data

[k kaggle.com](https://www.kaggle.com)


DATA SOURCE

資料來源



資料集：FETAL HEALTH CLASSIFICATION DATASET

研究目的



對胎兒健康狀況進行分類，以預防兒童和孕產婦死亡。

TABLE OF CONTENT

⊕ 任務說明
Task Description

⊕ 資料說明
Data Description

⊕ 資料分析
Exploratory Data Analysis, EDA


⊕ 資料處理
Data Preprocessing

⊕ 多種實驗設計
Experiments ; KNN、Random Forest、Decision Tree、
Naive Bayes

⊕ 實驗分析
Result Analysis

⊕ 結論與討論
Conclusion & Discussion

任務說明



問題背景與動機

降低兒童和孕產婦死亡率是全球性的重要目標。**胎心監護儀 (CTGs)** 用於評估胎兒健康狀況。CTG 記錄了胎兒心率 (FHR) 和子宮收縮等數據。

通過分析 **CTG 提取的數據特徵**，可以及時評估胎兒的健康狀態，以便醫療專業人員能夠採取預防措施，從而降低孕產婦死亡率。

任務目標

建構 **MLP 模型進行分類任務**，比較不同資料縮放、編碼方式與模型深度的預測準確率。

訓練 **XGBoost 作為對照模型**，並與 **MLP 比較效能差異**。

建立一套完整的深度學習與機器學習流程，包含資料處理、模型訓練、參數調整、模型比較與結果統整。

預期成果

提升胎兒健康分類準確率，並找到最佳的 **MLP 模型組合**。


完成 **12 組 MLP 與 1 組 XGBoost 的模型比較分析**，呈現不同資料處理方式與模型設計對效能的影響。

產生完整模型評估結果，各項指標 (P/R/F1)。

資料說明


資料筆數：2126筆

欄位分成以下這五部分：




- 1. 胎心率（FHR）與基本活動：BASELINE VALUE（基礎值）、ACCELERATIONS（加速）、FETAL_MOVEMENT（胎動）、UTERINE_CONTRACTIONS（子宮收縮）
- 2. 胎心率減速（DECELERATIONS）：LIGHT_DECELERATIONS（輕度減速）、SEVERE_DECELERATIONS（重度減速）、PROLONGUED_DECELERATIONS（延長減速）
- 3. 變異性（VARIABILITY）：ABNORMAL_SHORT_TERM_VARIABILITY（短期變異性異常）、MEAN_VALUE_OF_SHORT_TERM_VARIABILITY（短期變異性平均值）、MEAN_VALUE_OF_LONG_TERM_VARIABILITY（長期變異性平均值）、PERCENTAGE_OF_TIME_WITH_ABNORMAL_LONG_TERM_VARIABILITY（異常長期變異性佔比）

資料說明



- 4.直方圖特徵 (HISTOGRAM FEATURES) : HISTOGRAM_WIDTH (寬度)、HISTOGRAM_MIN (最小值)、HISTOGRAM_MAX (最大值)、HISTOGRAM_NUMBER_OF_PEAKS (峰值數量)、HISTOGRAM_NUMBER_OF_ZEROES (零頻數)、HISTOGRAM_MODE (眾數)、HISTOGRAM_MEAN (平均數)、HISTOGRAM_MEDIAN (中位數)、HISTOGRAM_VARIANCE (方差)、HISTOGRAM_TENDENCY (趨勢)
- 5.目標變量 (TARGET VARIABLE) : FETAL_HEALTH(胎兒健康狀態分類)

資料說明




- 1.FETAL_HEALTH(胎兒健康狀態分類)：預測的目標。標示胎兒健康狀態。
- 2.樣本數與分佈情形：數據不平衡，數據集存在明顯的類別不平衡問題。下一頁->
- 3.缺值(MISSING VALUES)：無明顯缺值。
- 4.異常值 (OUTLIERS)：由於所有特徵都是醫學測量值，這些異常值可能代表真實的極端醫學狀況。無刪除。
- 5.重複值(DUPLICATE VALUE)：檢查出13筆重複資料。將13筆資料刪除。

DATA DESCRIPTION

資料說明

數值	類別		說明
1	Normal	正常	胎兒健康狀況良好。
2	Suspect	可疑	胎兒健康狀況值得懷疑，需要進一步觀察。
3	Pathological	病理	胎兒健康狀況異常，存在病理風險。



FETAL HEALTH CLASSIFICATION


▲ 目標欄位長條圖：胎兒健康類別分佈

資料分析


皮爾森相關係數熱圖->

多數直方圖特徵（`histogram_mode`, `histogram_mean`, `histogram_median`）彼此之間以及與 `baseline value` 之間，呈現出極強的正相關。

`prolongued_decelerations` 與 `percentage_of_time_with_abnormal_long_term_variability` 呈中等正相關



Baseline Fetal Heart Rate vs Histogram Mean



這張散佈圖比較了兩個重要的胎心監護特徵：Baseline Fetal Heart Rate (BPM) (X 軸) 和 Histogram Mean (BPM) (Y 軸)，並根據胎兒健康類別進行了著色區分。

FETAL HEALTH CLASSIFICATION

資料分析


▲ 基線胎心率 (Baseline Fetal Heart Rate)



資料處理

- 基礎資料處理
 - 去除重複值
- 編碼方式：
 - one-hot encoding
 - label encoding
- 正規化，標準化
- 資料切分（Train/Test, Validation）6：2：2

->清理後資料筆數： 2113




本實驗旨在回答以下研究問題：

1. 刪除欄位與否是否營響訓練模型？
2. 不同資料縮放方式是否會影響 MLP 效能？
3. 不同類別編碼方式對模型表現是否有差異？
4. 不同模型深度是否會提升預測能力？
5. 在所有模型之中，哪一個為最佳 MLP 組合？
6. XGBOOST 是否能在表格資料中勝過 MLP？


為解決上述問題，本研究設計了共 12 組 MLP 實驗
與 1 組 XGBoost 實驗進行比較。

Step 1 — 比較刪除欄位 vs 不刪除 (1 次實驗)




多種實驗設計

實驗	Loss	Accuracy	Precision	Recall	F1 Score
刪除欄位	0.253	0.8936	0.8128	0.6986	0.7444
不刪除欄位	0.2469	0.8936	0.8531	0.7455	0.7905



結果顯示兩者在 Accuracy、Loss、Precision、Recall 與 F1-score 上的差異並不顯著，屬於深度學習模型中常見且合理的現象。




Step 2 — 12 組實驗

模型建構 — MLP模型設計

研究比較三種不同深度的 MLP 架構


模型名稱	隱藏層數	結構 units
Small	1	[64]
Medium	2	[128, 64]
Large	2	[256, 128]



模型建構 — MLP模型設計

所有模型使用


超參數	值
Optimizer	Adam(lr=0.001)
Loss	categorical_crossentropy
Epochs	50 (EarlyStopping 可提前停止)
Batch Size	32
Dropout	0.3
Activation	ReLU
Output	Softmax(3 類)



模型建構 — 訓練技巧

使用三種訓練加速與防止過擬合的方法：

技術	說明
EarlyStopping (patience=5)	防止過度訓練、提升泛化能力
Dropout 0.3	減少 co-adaptation、降低 overfitting
BatchNormalization (部分模型)	使訓練更穩定




實驗矩陣 (Experiment Matrix)

為比較不同前處理策略與模型架構，設計以下 12 種 MLP 實驗組合：

編碼方式	縮放方式	模型架構
Label Encoding	正規化	Small / Medium / Large
Label Encoding	標準化	Small / Medium / Large
One-Hot Encoding	正規化	Small / Medium / Large
One-Hot Encoding	標準化	Small / Medium / Large


多種實驗設計



實驗編號	編碼方式	縮放方式	模型架構	隱藏層	Units
E1	Label	Standard	Small	1	[64]
E2	Label	Standard	Medium	2	[128,64]
E3	Label	Standard	Large	2	[256,128]
E4	Label	MinMax	Small	1	[64]
E5	Label	MinMax	Medium	2	[128,64]
E6	Label	MinMax	Large	2	[256,128]
E7	OneHot	Standard	Small	1	[64]
E8	OneHot	Standard	Medium	2	[128,64]
E9	OneHot	Standard	Large	2	[256,128]
E10	OneHot	MinMax	Small	1	[64]
E11	OneHot	MinMax	Medium	2	[128,64]
E12	OneHot	MinMax	Large	2	[256,128]


FETAL HEALTH CLASSIFICATION

多種實驗設計



Experiment	Loss	Accuracy	Precision	Recall	F1
E1_label_standard_small	0.2575	0.8913	0.8709	0.7561	0.8021
E2_label_standard_medium	0.2244	0.9031	0.8201	0.7577	0.7858
E3_label_standard_large	0.2383	0.9007	0.8224	0.7387	0.7749
E4_label_minmax_small	0.2521	0.896	0.854	0.7673	0.8051
E5_label_minmax_medium	0.2206	0.9102	0.82	0.8013	0.8103
E6_label_minmax_large	0.2137	0.9078	0.8604	0.8043	0.8301
E7_onehot_standard_small	0.4656	0.8605	0.7773	0.7532	0.7644
E8_onehot_standard_medium	0.3636	0.8723	0.8379	0.7216	0.7674
E9_onehot_standard_large	0.4022	0.87	0.8356	0.7444	0.7772
E10_onehot_minmax_small	0.28	0.9078	0.8937	0.7437	0.8017
E11_onehot_minmax_medium	0.3035	0.8983	0.8718	0.7417	0.7941
E12_onehot_minmax_large	0.3188	0.9007	0.873	0.6893	0.7495

FETAL HEALTH CLASSIFICATION






EXPERIMENTS : MLP

神經網路多層感知機(Multilayer Perceptron, MLP)

12 種 MLP 實驗組合，取最好的兩組實驗展試圖表：

1.E5_label_minmax_medium








EXPERIMENTS : MLP

神經網路多層感知機(Multilayer Perceptron, MLP)

12 種 MLP 實驗組合，取最好的兩組實驗展試圖表：

2.E6_label_minmax_large






EXPERIMENTS : XGBOOST

XGBoost 分類器(eXtreme Gradient Boosting)

本研究另外訓練 XGBOOST (多類模型) 作為對照組


- `n_estimators = 300`
- `learning_rate = 0.05`
- `max_depth = 5`
- `objective = multi:softprob`
- 評估指標：Accuracy / F1 / Precision / Recall / 混淆矩陣



XGBoost 分類器(eXtreme Gradient Boosting)

本研究另外訓練 XGBOOST（多類模型） 作為對照組

實驗	Accuracy	Precision	Recall	F1 Score
XGBoost	0.9314	0.927	0.8324	0.8715




實驗分析

模型表現比較表


Experiment	Loss	Accuracy	Precision	Recall	F1
E5_label_minmax_medium	0.2206	0.9102	0.82	0.8013	0.8103
E6_label_minmax_large	0.2137	0.9078	0.8604	0.8043	0.8301
XGBoost	XXXX	0.9314	0.927	0.8324	0.8715

- XGBoost 在所有模型中準確率最高，為本研究最佳分類模型。
- 12 組 MLP 的表現非常接近，顯示模型對資料前處理具高穩定性。
- MinMax + One-Hot + Medium/Large 架構為 MLP 的最佳組合。
- Small 模型因參數較少，學習能力較弱，整體表現較低。
- One-Hot 通常優於 Label Encoding，尤其在深層 MLP 架構中更明顯。

MLP vs XGBoost Accuracy Comparison



- XGBoost 在所有模型中準確率最高，為本研究最佳分類模型。
- 12 組 MLP 的表現非常接近，顯示模型對資料前處理具高穩定性。
- MinMax + One-Hot + Medium/Large 架構為 MLP 的最佳組合。



結論與討論-整體實驗結論

結論一：XGBoost 表現卓越，穩居榜首

- XGBoost 在所有評估指標上，全面優於所有 MLP 模型。
- 優勢原因：XGBoost 對表格型數據具備高效的學習能力，展現最佳的分類準確度與泛化能力。

結論二：MLP 深度結構優於淺層，最佳組合表現穩定

- MLP 十二組模型整體差異不大，但深度結構表現較具優勢。
- MLP 最佳組合：MinMaxScaler + One-Hot Encoding + Medium/Large 架構，其整體表現穩定，與 XGBoost 僅有微小差距。

深度學習 第二次作業



NOVEMBER 2025

謝謝大家

THANK YOU EVERYONE

112316107 洪翊慈