






Medical Examination Dataset Analysis

Analyzing cardiovascular disease (CVD) risk and other health conditions.

[k kaggle.com](https://www.kaggle.com)


SCIENTIFIC STEPHEN

資料來源



公開醫療檢查紀錄資料集：MEDICAL EXAMINATION DATASET ANALYSIS

研究目的



使用醫療資料做分類實驗，判斷有沒有心血管疾病。

TABLE OF CONTENT

⊕ 任務說明
Task Description

⊕ 資料說明
Data Description

⊕ 資料分析
Exploratory Data Analysis, EDA


⊕ 資料處理
Data Preprocessing

⊕ 多種實驗設計
Experiments ; KNN、Random Forest、Decision Tree、
Naive Bayes

⊕ 實驗分析
Result Analysis

⊕ 結論與討論
Conclusion & Discussion

任務說明



問題背景與動機

心血管疾病(CVD)是全球主要的健康威脅之一。包括生理指標和生活習慣都與心血管疾病的風險密切相關。

本次動機在於利用大量患者醫療檢查紀錄的數據集，來分析不同因素是如何共同影響個體的狀況。透過數據分析和機器學習，提早識別高風險人群。

任務目標

此任務的主要目標是一個「二元分類」問題。


數據集中包含多項特徵，以及一個目標變量(標籤)，通常標記為「cardio」。

預測目標：根據患者的各項生理指標和生活習慣特徵，預測該患者是否存在CVD。

預期成果

1. 特徵分析: 透過分析和統計，識別哪些是預測CVD的重要特徵，分析不同生活習慣對CVD的影響。
2. 模型比較: 建立、訓練多種不同的分類模型，再比較這些模型預測CVD的表現。
3. 準確率提升: 透過模型調參優化最佳模型的預測能力，以達到最高的預測準確度。

資料說明



資料筆數：70000筆

分成以下這四部分：

1. 基本客觀特徵：

A. **AGE (年齡)**、GENDER (性別)、HEIGHT (身高)、WEIGHT (體重)

2. 生理檢查（客觀特徵）：


A. AP_HI (收縮壓 / 上壓)、AP_LO (舒張壓 / 下壓)、CHOLESTEROL (膽固醇)、GLUC (血糖)

3. 生活習慣（主觀特徵）：

A. SMOKE (吸煙)、ALCO (飲酒)、ACTIVE (體能活動)

4. 目標變量 (TARGET VARIABLE)；**CARDIO (心血管疾病)**


資料說明




1. AGE (年齡)：由於單位為天，加入 **AGE_YEARS** 欄位。
2. CARDIO (心血管疾病)：預測的目標。標示患者是否存在心血管疾病。
3. 樣本數與分佈情形：目標欄位樣本數基本上為1：1平均分配。下一頁左圖->
4. 缺值(MISSING VALUES)：無缺值，不需要使用插補法來填補缺值。
5. 異常值 (OUTLIERS)：存在大量不合邏輯或極端的數據點，主要的異常值集中在生理客觀特徵，特別是血壓、身高和體重。

資料説明

心血管疾病分布 (0=否, 1=是)



年齢分佈



資料分析

皮爾森相關係數熱圖->


0.2以下為無相關

0.2~0.4為低度相關


0.4~0.6為中度相關

0.6~0.8為高度相關


0.8以上為線性相關




age_years 與心血管疾病關係




height 與心血管疾病關係




weight 與心血管疾病關係



ap_hi 與心血管疾病關係



ap_lo 與心血管疾病關係




- 左上圖，可看出有心血管疾病的人群年齡相較之下較高。
- 右上圖，可看出有心血管疾病的人群體重相較之下較高。
- 下面兩張圖，可看出血壓較高的人，比較有可能有心血管疾病。


資料分析

資料分析


gender 與心血管疾病關係




cholesterol 與心血管疾病關係




gluc 與心血管疾病關係




smoke 與心血管疾病關係



alco 與心血管疾病關係



active 與心血管疾病關係






資料處理

- 基礎資料處理
 - 加入 age_years 欄位
 - 移除不合理的血壓值
 - 去除 gender 中的錯誤值
 - 去除離群值
 - 去除重複值
- 編碼方式；one-hot encoding
- 正規化，標準化
- 資料切分（Train/Test）：8：2

->清理後資料筆數： 62492




EXPERIMENTS : KNN

K-近鄰演算法(k-nearest neighbor classification, KNN)

調參方式：GRIDSEARCHCV 參數：P=1(曼哈頓距離) P=2(歐幾里得距離)


編號	資料切分	最佳準確率	最佳參數	資料處理方式
1	Train/Test (5-Fold)	0.707097	{‘n_neighbors’: 20, ‘p’: 2}	正規化
2	Train/Test (5-Fold)	0.712377	{‘n_neighbors’: 20, ‘p’: 1}	正規化+OneHot
3	Train/Test (5-Fold)	0.706297	{‘n_neighbors’: 20, ‘p’: 1}	標準化
4	Train/Test (5-Fold)	0.715657	{‘n_neighbors’: 20, ‘p’: 1}	標準化+OneHot
5	Train/Test (10-Fold)	0.713897	{‘n_neighbors’: 20, ‘p’: 2}	標準化+OneHot



EXPERIMENTS : KNN

K-近鄰演算法(k-nearest neighbor classification, KNN)

編號	Accuracy	Precision	Recall	F1	AUC
1	0.707097	0.727043	0.651547	0.687228	0.762621
2	0.712377	0.735735	0.651709	0.691178	0.771187
3	0.706297	0.727786	0.647497	0.685298	0.762762
4	0.715657	0.740761	0.652681	0.693937	0.774297
5	0.713897	0.739002	0.650413	0.691884	0.773639




EXPERIMENTS : DECISION TREE

決策樹 (Decision Tree)

調參方式：GRIDSEARCHCV 參數：MAX_DEPTH(限制樹最多只能向下分裂的層數)


編號	資料切分	最佳準確率	最佳參數	資料處理方式
1	Train/Test (5-Fold)	0.709017	{'max_depth': 5}	正規化
2	Train/Test (5-Fold)	0.721338	{'max_depth': 5}	正規化+OneHot
3	Train/Test (5-Fold)	0.709017	{'max_depth': 5}	標準化
4	Train/Test (5-Fold)	0.721338	{'max_depth': 5}	標準化+OneHot
5	Train/Test (10-Fold)	0.722618	{'max_depth': 7}	標準化+OneHot



EXPERIMENTS : DECISION TREE

決策樹 (Decision Tree)

編號	Accuracy	Precision	Recall	F1	AUC
1	0.709017	0.719910	0.672445	0.695368	0.773988
2	0.721338	0.744457	0.663535	0.701670	0.781834
3	0.709017	0.719910	0.672445	0.695368	0.773988
4	0.721338	0.744457	0.663535	0.701670	0.781834
5	0.722618	0.744931	0.666613	0.703599	0.783797




EXPERIMENTS : RONDON FOREST

隨機森林 (Rondon Forest)

調參方式：GRIDSEARCHCV 參數：MAX_DEPTH N_ESTIMATORS(樹木數量)


編號	資料切分	最佳準確率	最佳參數	資料處理方式
1	Train/Test (5-Fold)	0.713177	{ 'max_depth': 10, ', 'n_estimators': 100}	正規化
2	Train/Test (5-Fold)	0.725418	{ 'max_depth': 15, ', 'n_estimators': 200}	正規化+OneHot
3	Train/Test (5-Fold)	0.713177	{ 'max_depth': 10, ', 'n_estimators': 100}	標準化
4	Train/Test (5-Fold)	0.725178	{ 'max_depth': 15, ', 'n_estimators': 200}	標準化+OneHot
5	Train/Test (10-Fold)	0.724058	{ 'max_depth': 15, ', 'n_estimators': 200}	標準化+OneHot



EXPERIMENTS : RONDON FOREST

隨機森林（Rondon Forest）

編號	Accuracy	Precision	Recall	F1	AUC
1	0.713177	0.727177	0.670987	0.697953	0.779144
2	0.725418	0.744078	0.676818	0.708856	0.790888
3	0.713177	0.727097	0.671149	0.698004	0.779147
4	0.725178	0.743681	0.676818	0.708676	0.790858
5	0.724058	0.741062	0.678276	0.708280	0.790384




EXPERIMENTS : BAYESIAN CLASSIFIER

貝氏分類器 (Bayesian Classifier)

實驗模型：GAUSSIAN NAIVE BAYES 調參方式：GRIDSEARCHCV


編號	資料切分	最佳準確率	資料處理方式
1	Train/Test (5-Fold)	0.700376	正規化
2	Train/Test (5-Fold)	0.680854	正規化+OneHot
3	Train/Test (5-Fold)	0.700376	標準化
4	Train/Test (5-Fold)	0.705416	標準化+OneHot
5	Train/Test (10-Fold)	0.705416	標準化+OneHot



EXPERIMENTS : BAYESIAN CLASSIFIER

貝氏分類器 (Bayesian Classifier)

編號	Accuracy	Precision	Recall	F1	AUC
1	0.700376	0.763798	0.569415	0.652436	0.771221
2	0.680854	0.719718	0.579459	0.645017	0.749239
3	0.700376	0.763798	0.569415	0.652436	0.771221
4	0.705416	0.724293	0.651547	0.685997	0.759566
5	0.705416	0.724293	0.651547	0.685997	0.759566




EXPERIMENTS : SVM

支持向量機 (Support Vector Machine, SVM)

調參方式：GRIDSEARCHCV 參數：KERNEL和函數種類， C 容錯率

編號	資料切分	最佳準確率	最佳超參數	資料處理方式
1	Train/Test (5-Fold)	0.731259	{'C': 10, 'kernel': 'rbf'}	正規化
2	Train/Test (5-Fold)	0.730459	{'C': 1, 'kernel': 'rbf'}	正規化+OneHot
3	Train/Test (5-Fold)	0.731899	{'C': 1, 'kernel': 'rbf'}	標準化
4	Train/Test (5-Fold)	0.731419	{'C': 1, 'kernel': 'rbf'}	標準化+OneHot



EXPERIMENTS : SVM

支持向量機 (Support Vector Machine, SVM)

編號	Accuracy	Precision	Recall	F1	AUC
1	0.731259	0.769651	0.650894	0.705274	0.78799
2	0.730459	0.774337	0.641329	0.701547	0.787919
3	0.731899	0.762331	0.664365	0.709982	0.786339
4	0.731419	0.76604	0.65696	0.707287	0.788144

實驗分析


模型表現比較表

Random Forest F1和AUC最高且穩定，適合應用實務。
SVM準確率最高。Decision Tree 與 KNN 表現中等，可
作為備選。Naive Bayes 表現最差，不建議實際使用。


模型(Model)	Accuracy	F1 Score	AUC	資料處理方式
KNN	0.715657	0.693937	0.774297	標準化+OneHot
Decision Tree	0.722618	0.703599	0.783797	標準化+OneHot
Random Forest	0.725418	0.708856	0.790888	正規化+OneHot
Naive Bayes	0.705416	0.685997	0.759556	標準化+OneHot
SVM	0.731899	0.709982	0.786339	標準化

實驗分析


KNN




Decision Tree




Random Forest



Naive Bayes




SVM




- Random Forest 模型在 AUC (0.790888) 與 F1(0.708856) 分數上表現最佳，能較有效區分高風險個體。
- SVM 準確率最高，對 1 類（患病者）辨識能力優異。
- Decision Tree 與 KNN 整體表現中等，TP 與 TN 分布均衡。
- Naive Bayes 的誤判率偏高，FN與 FP均為五模型中最差。
- 混淆矩陣清楚顯示各模型在「正確預測」與「誤分類」間的差異，輔助模型選擇判斷。

實驗分析

ROC Curve - 五模型比較




綜合比較五種模型的分類表現與 ROC 曲線，隨著特徵標準化與超參數調整，Random Forest 在整體準確性與辨識能力上表現最佳，建議作為本預測任務的首選模型。



結論與討論-整體實驗結論

本研究比較五種機器學習模型預測心血管疾病風險，結果顯示：

- **Random Forest 準確率與 AUC 均為最高**(AUC =0.79)，為最佳預測模型。
- SVM 精準度與召回率佳，適合重視風險偵測的應用。
- KNN 與 Decision Tree 表現穩定，適合作為備用模型。
- Naive Bayes 效果最差，不建議實務應用。
- 模型搭配正確的資料前處理策略（如標準化與 One-Hot）可顯著提升效能。



謝謝大家

THANK YOU EVERYONE